

Lucas Amaral Dourado

Engenharia de Dados • Python • SQL • ETL/ELT • Engenharia de Software

Goiânia, GO

Desenvolvedor Python com foco em engenharia de dados e engenharia de software: arquitetura e construção de plataformas envolvendo pipelines de dados, integração de fontes heterogêneas, APIs, processamento assíncrono, sistemas geoespaciais e aplicações analíticas.

Atuo no PET — Saúde Informação & Saúde Digital da UFT, participando do desenvolvimento da arquitetura do LabSUS, plataforma de inteligência em saúde pública voltada à ingestão, processamento, integração e análise de grandes volumes de dados provenientes de múltiplos sistemas nacionais.

Meu portfólio inclui projetos autorais nas áreas de engenharia de dados, geoprocessamento, interoperabilidade semântica, arquitetura backend, sistemas distribuídos, ciência de dados e desenvolvimento full-stack, incluindo LabSUS, Dê um Rolê, Brazilian Public Health Ontology e BioSpace.


Atualmente curso Análise e Desenvolvimento de Sistemas na PUC Goiás, com formação prévia de dois anos e meio em Medicina pela Universidade Federal do Tocantins — experiência que contribui para minha capacidade de compreender, estruturar e modelar problemas de alta complexidade.

↗ labsus.com.br

in LinkedIn

GitHub

🏠 Lattes



• PLATAFORMA • P&D EM SAÚDE PÚBLICA

PROJETO PRINCIPAL

LabSUS

"Dados brutos do SUS viram decisão, não planilha."

Plataforma modular de engenharia e inteligência de dados para integrar, processar e analisar grandes volumes de informações do sistema brasileiro de saúde, concebida como infraestrutura aberta, reproduzível e independente de serviços proprietários.

- Pipelines de ingestão, transformação e integração de bases nacionais (SIM, SINASC, SIH, SIA, SINAN, CNES, IVS, IBGE), processando múltiplos anos e unidades federativas.
- Backend em Django com APIs para consumo dos resultados analíticos e execução assíncrona via Celery e Redis.
- Desenvolvimento de aproximadamente 50 modelos estatísticos e de machine learning (séries temporais, análise de sobrevivência, modelagem preditiva, clusterização territorial, inferência causal, entre outros).
- Frontend analítico em React com dashboards interativos e visualizações geoespaciais em Plotly.

Python • Django • DRF • PostgreSQL • Celery • Redis • React • Plotly • PySUS

8

BASES NACIONAIS INTEGRADAS

~50

MODELOS ESTATÍSTICOS E DE ML

assíncrono

VIA CELERY + REDIS

código aberto

INFRAESTRUTURA REPRODUTÍVEL

[➔ labsus.com.br](https://labsus.com.br) [repositório](#)

— ESPECIFICAÇÃO TÉCNICA — ESTADO FINAL

BPHO — Brazilian Public Health Ontology

github.com/goldenLuke/BPHO

Versão v50. Um modelo formal — em OWL 2 DL e SHACL — de como o Sistema Único de Saúde brasileiro produz, fragmenta, revisa e versiona seus próprios registros administrativos. 28 axiomas, todos verificados por reasoner de lógica de descrição, consulta agregada em escala real, ou ambos.

28

axiomas, nenhum revertido

6/6

sistemas em cobertura total de arquivo

48/49

bases de agravos testadas

56, 6M

triplas reais, cobertura nacional

0

trata todo dado como resultado de um ato de medir e interpretar, nunca um fato bruto, com proveniência obrigatória alinhada a PROV-O.

O núcleo foi testado contra os seis sistemas administrativos originais do SUS — com cobertura completa dos grupos de arquivo declarados pelo PySUS em cinco deles e 48 de 49 bases de agravos no sexto — mais três sistemas fora do desenho administrativo original. Formalizado integralmente em OWL 2 DL + SHACL — nenhum dos 28 axiomas depende de SWRL. Verificado por reasoner de lógica de descrição (HermiT) e por consulta agregada direta (Oxigraph) em escala real: a checagem de consistência completa de ~90 mil indivíduos e ~700 mil triplas RDF termina em 60-61 segundos. Comparado formalmente contra quatro referências externas: BFO, SNOMED CT, HL7 FHIR e o OMOP Common Data Model.

 ONTOLOGIA FORMAL • OWL 2 DL + SHACL

BPHO

Brazilian Public Health Ontology — uma camada formal para o que os dados do SUS realmente podem afirmar.

Modelagem semântica do ecossistema brasileiro de dados de saúde pública, integrando conceitualmente fontes como SIM, SINASC, SIH, SIA, SINAN e CNES por meio de RDF, OWL, SHACL e consultas SPARQL, com execução independente e interfaces bem definidas de integração com o LabSUS.

- 28 axiomas formais, nenhum revertido, verificados por reasoner de lógica de descrição (HermiT) e por consulta SPARQL agregada contra dado real

via Oxigraph.

- Cobertura completa dos seis sistemas administrativos originais do SUS, com o SINAN chegando a 48 de 49 agravos declarados pelo PySUS.
- O próprio processo de formalização encontrou inconsistências lógicas reais no modelo, do tipo que passaria despercebida numa descrição em texto.

RDF · OWL · SHACL · SPARQL · Python · modelagem semântica

28

AXIOMAS FORMAIS, ZERO REVERTIDOS

6/6

SISTEMAS DO SUS COBERTOS

56, 6M


TRIPLAS RDF, ESCALA NACIONAL

Hermit

REASONER OWL/DL + SHACL

[↗ documentação](#)

[🔄 repositório](#)

 EN / PT Repository

REPRESENTATION INFRASTRUCTURE · NOT AN ML LIB

A patient is not a vector.

Algorithms never observe a patient. They observe representation built from exams, signals and observations. BioSpace treats that representation as an independent scientific problem — and makes it executable.

[Read the manuscript ↗](#) [View on GitHub ↗](#)

Explore the meta-model

$M = (B, O, D, R, X, G, F, C)$ — nine entities, one to any disease.

REPRESENTATION SPACE · LIVE DEMONSTRATION

[straight](#) [geode](#)

 FULL ACADEMIC PAPER

Mathematical Foundations of the Computational Representation of Biological Systems

The formal derivation of every entity, principle and contract on this page — with proofs, related work and the full OSAS case study.

[Read the manuscript ↗](#)

THE PROBLEM

The object no one defines

Most AI in healthcare implicitly assumes a patient can be reduced to a vector $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$. But that vector isn't the patient — it's just an arbitrary selection of attributes:

$x = f(P)$, and almost always $x \neq P$

Two studies on the same syndrome — Obstructive

● REPRESENTATION INFRASTRUCTURE · NÃO É UMA ML LIB

BioSpace

"A patient is not a vector."

Framework de pesquisa que trata a representação de sistemas biológicos — a transformação de dados observados em vetores e espaços matemáticos — como objeto explícito de investigação científica, decompondo o pipeline analítico em observação, representação, geometria e algoritmo, em vez de tratá-la como etapa implícita anterior ao algoritmo.

- Validação empírica em bases públicas reais (NHANES e UCI Diabetes 130-US Hospitals) e em uma coorte real de apneia do sono (dados de oximetria/actigrafia), mostrando que fixar a representação e variar apenas a geometria ou o algoritmo pode produzir conclusões opostas sobre a mesma população.
- Núcleo genérico por domínio de doença (apneia, diabetes, síndrome metabólica), construído sobre a mesma representação disease-neutral.
- Dashboard interativo em Streamlit com módulos de fenotipagem clínica, sobrevivência, inferência causal, domínios latentes, geometrias e sistemas dinâmicos.
- Suíte de testes automatizados e documentação técnica bilíngue (português e inglês).

Python · estatística · machine learning · representação multidimensional

9

ENTIDADES FORMAIS NO META-MODELO

3

BASES REAIS DE VALIDAÇÃO

Streamlit




DASHBOARD INTERATIVO MULTI-MÓDULO

EN / PT

DOCUMENTAÇÃO BILÍNGUE

↗ documentação

🔄 repositório



● PLATAFORMA GEOESPACIAL · DESCOBERTA URBANA

Dê um Rolê

"Sua cidade tem mais coisa acontecendo do que parece."

Plataforma social georreferenciada que conecta eventos, locais, organizações e pessoas a partir da atividade presencial de uma cidade, com forte foco em modelagem de domínio, integridade de dados e expansão multicidade.

- Pipeline de dados territoriais com bairros mapeados em todas as capitais do Brasil: normalização, deduplicação, reprojeção de coordenadas e correção de geometrias — 687 bairros válidos só na cidade piloto, Goiânia.
- Ingestão de estabelecimentos e eventos com associação espacial via PostGIS, matching, deduplicação e processos idempotentes de atualização.
- Sistema de descoberta e ranking combinando proximidade, popularidade, afinidade, distância geográfica e categoria.
- Mais de 400 testes automatizados, executados contra PostgreSQL/PostGIS real, cobrindo domínio, autenticação, APIs e segurança.
- Autenticação por token, RBAC para organizações, rate limiting e logging estruturado.

Python · Django · Django Ninja · PostgreSQL/PostGIS · Redis · Docker · React · TypeScript

27

CAPITAIS DO BRASIL COM BAIRROS MAPEADOS

687

BAIRROS VÁLIDOS NA CIDADE PILOTO, GOIÂNIA

400+

TESTES CONTRA POSTGIS REAL

privado

CÓDIGO FECHADO

➔ deumrole.com

código fechado – sem repositório público

COMPETÊNCIAS TÉCNICAS

Engenharia de dados

Python

SQL

ETL/ELT

Pipelines de dados

Integração de fontes heterogêneas

Qualidade e validação de dados

Processos idempotentes

Automação de fluxos

Processamento multitemporal e multiestadual

Bancos de dados e armazenamento

PostgreSQL

PostGIS

Redis

Modelagem relacional

Consultas espaciais

Modelagem de domínios complexos

Backend e integrações

Django

Django REST Framework

Django Ninja

APIs REST

Celery

Processamento assíncrono

RBAC

Autenticação e autorização

Paginação por cursor

Infraestrutura e ferramentas

Docker

Docker Compose

Git

Linux

Logging estruturado

Rate limiting

Observabilidade básica

Dados, estatística e machine learning

Pandas

PySUS

Bioestatística

Séries temporais

Análise de sobrevivência

Modelagem preditiva

Clusterização

Inferência causal

Redução de dimensionalidade

Geoprocessamento

GeoJSON

Sistemas de coordenadas

Reprojeção geográfica

Associação ponto-polígono

Mapas interativos

Frontend e visualização

React

TypeScript

JavaScript

Plotly

Vite

Tailwind CSS

Web semântica e interoperabilidade

RDF

OWL

SHACL

SPARQL

Ontologias

Triple stores

EXPERIÊNCIA

jan/2026
– atual

Pesquisador voluntário — Engenharia de Dados e Saúde Digital

PET Saúde Informação & Saúde Digital, UFT · híbrido

Atuação no desenvolvimento e manutenção da arquitetura do LabSUS-UFT, com foco em engenharia de dados aplicada a sistemas públicos de saúde, processamento de grandes volumes de dados e construção de infraestrutura analítica reproduzível.

- Desenvolvimento de pipelines para ingestão, processamento, transformação, integração e disponibilização de dados provenientes de bases nacionais de saúde (SIM, SINASC, SIH, SIA, SINAN, CNES, IVS, IBGE).
- Automação de fluxos em Python, padronizando o processamento de múltiplos períodos e unidades federativas.
- Construção de matrizes e indicadores epidemiológicos reprodutíveis e auditáveis.

- Desenvolvimento de APIs em Django REST e implementação de processamento assíncrono com Celery e Redis.
- Participação no desenvolvimento de dashboards em React e Plotly, e de modelos estatísticos e de machine learning aplicados à epidemiologia computacional.

abr/2026

Harvard HSIL Hackathon 2026 — participante

Harvard Health Systems Innovation Lab, Brasília, DF

Desenvolvimento de solução analítica baseada em dados do DATASUS para investigar a relação entre HPV e câncer do colo do útero, integrando múltiplas bases e construindo pipelines automatizados com Python e PySUS orientados ao suporte à tomada de decisão baseada em evidências.

FORMAÇÃO ACADÊMICA

Análise e Desenvolvimento de Sistemas

Pontifícia Universidade Católica de Goiás — PUC Goiás

jan/2026 — previsão jan/2028

Medicina

Universidade Federal do Tocantins — UFT · 2 anos e meio cursados

Formação prévia em ciências da saúde, metodologia científica e raciocínio clínico, aplicada hoje ao desenvolvimento de sistemas, engenharia de dados e epidemiologia computacional.

CERTIFICAÇÕES

Master Statistics with Python Skill Path

Codecademy · fev/2024

08FC4926-E

Fundamental Math for Data Science Skill Path

Codecademy · jul/2024

C30E943D-B

Intro to Machine Learning Course

Codecademy · jun/2025

BB8E3A51-D

LabSUS · BPH0 · BioSpace · Dê um Rolê — projetos de github.com/goldenluke